

Hierarchisches Clustering von Kinect-Bewegungsdaten mittels Dynamic Time Warping

Bachelorarbeit von

Laurenz Fuchs

1196307

Draft vom 15. April 2022

Erstprüfer: Prof. Dr. Michael Koch

Zweitprüfer: Prof. Dr. Gunnar Teege

Betreuer: M. Sc. Julian Fietkau

Abgabetermin: 31. Mai 2022

Universität der Bundeswehr München

Fakultät für Informatik

Abstract

Im Rahmen des *HoPE-Projekts* wird das Verhalten von Menschen bei der Nutzung von *Ambient Displays* analysiert. Dazu soll auch ein methodisches Rahmenwerk entwickelt werden, welches eine Evaluation von Sensordaten ermöglicht. Tiefenkameras werden seit vielen Jahren in der Forschung genutzt, um Bewegungsabläufe aufzunehmen. Solche Bewegungsdaten sind sogenannte Time-Series Data. Ziel dieser Arbeit ist es ein Software-Tool zu entwickeln, welches derartige Datensätze clustern kann. Dazu soll *hierarchisches Clustering* mithilfe des *Dynamic Time Warping Algorithmus* zum Einsatz kommen. Die Wahl der Algorithmen wird begründet. Zudem erfolgt eine ausführliche Beschreibung dieser. Anschließend wird die Konzeption und Implementierung des Tools dargestellt. Die Software wurde dabei so allgemein gestaltet, dass sie für verschiedene Datensätze verwendet werden kann. Auch mögliche Limitierungen werden beschrieben. Abschließend erfolgt ein Clustering von *Kinect-Bewegungsdaten*. Mithilfe einer Ground-Truth-Analyse und deskriptiven Statistiken wird die Qualität der gefundenen Cluster überprüft. Diese Analyse zeigt, dass das entwickelte Tool zum Clustering von Time-Series Data genutzt werden kann.

Inhaltsverzeichnis

1	Einleitung und Motivation	1
1.1	Einleitung	1
1.2	Motivation	1
2	Grundlagen und Problembeschreibung	3
2.1	Kategorien der Interaktion mit Wandbildschirmen	3
2.2	Spezifikation der Kinect	4
2.3	Struktur des vorliegenden Datensatzes	5
2.4	Problembeschreibung	7
3	Clustering von Bewegungsdaten mittels Dynamic Time Warping	10
3.1	Hierarchisches Time-Series Clustering	10
3.2	Dynamic Time Warping Algorithmus	11
3.3	Veranschaulichendes Beispiel	12
3.4	Related Work Analyse	14
3.5	Einsatz im Kontext von Kinect-Bewegungsdaten	16
4	Konzeption	17
4.1	Anforderungsanalyse	17
4.1.1	Nicht-funktionale Anforderungen	17
4.1.2	Funktionale Anforderungen	18
4.2	Programmablauf	18
4.3	Teilsysteme	20
5	Implementierung	22
5.1	Aufbau	22
5.2	Codebeschreibung	24
5.3	Abweichungen zur Konzeption	29
6	Evaluation	33
6.1	Einführende Bemerkungen	33
6.2	Ground-Truth Analyse	34
6.3	Statistische Analyse	36
7	Fazit	43
	Abbildungsverzeichnis	44
	Abkürzungsverzeichnis	45
	Listingsverzeichnis	46
	Tabellenverzeichnis	47
	Literaturverzeichnis	48

1 Einleitung und Motivation

1.1 Einleitung

am Ende die Kapitel der Arbeit nacheinander durchgehen und deren Kernzweck zusammenfassen

1.2 Motivation

Von September 2021 bis August 2024 forschen die Hochschule für angewandte Wissenschaften in Hamburg und die Universität der Bundeswehr München im Rahmen des *HoPE-Projekts* zusammen an Effekten rund um die Steigerung der Aufmerksamkeit bei der Nutzung von großen, interaktiven Wandbildschirmen, sogenannten *Ambient Displays*. Dieser Bereich weist noch einen grundsätzlichen Forschungsbedarf auf. Im Projekt wird unter anderem der *Honeypot-Effekt* erforscht (UniBw, 2021). Dieser beschreibt in der Mensch-Computer-Interaktion (HCI) wie Menschen, die mit einem System interagieren, weitere Passanten anregen die Interaktion zu beobachten oder sogar an ihr teilzuhaben (Wouters et al., 2016). Der *Honeypot-Effekt* soll bei der Nutzung von *Ambient Displays* im öffentlichen und halb-öffentlichen Raum in Langzeit-Feldstudien analysiert werden. Dabei soll auch der Aspekt der Datenerhebung und -analyse weiter ausgebaut werden. Hierzu muss ein methodisches Rahmenwerk entwickelt werden, welches eine auf Sensordaten-basierende, automatische und zeitlich uneingeschränkte Evaluation von *Ambient Displays* ermöglicht (UniBw, 2021). Die Sensordaten werden von Body-Tracking-Kameras bereitgestellt. Konkret wurden die Wandbildschirme im vorliegenden Datensatz mit Microsoft Kinect v2 Kameras ausgestattet. Diese zeichnen die Interaktion von Nutzern mit den Displays auf, wodurch das Nutzerverhalten zu einem späteren Zeitpunkt ausgewertet werden kann. Die Daten liegen als Time-Series Data (TSD) vor. Bei diesem Datentyp handelt es sich um geordnete Sequenzen von Datenpunkten, die über eine gewisse Zeit hinweg aufgenommen werden (Ali et al., 2019). TSD enthalten oft wichtige Informationen die durch Mustererkennung entdeckt werden können.

Eine gängige Methode zur Analyse sind hierbei *Clustering*-Verfahren (Aghabozorgi et al., 2015). Lässt sich eine Menge von Kategorien identifizieren, die etwas über das Verhalten von Menschen vor Wandbildschirmen aussagt? Ist die Einteilung in diese Kategorien automatisierbar? Aufgrund der Größe des vorliegenden Datensatzes ist eine manuelle Evaluation zur Beantwortung der Fragen nicht möglich. In dieser Bachelorarbeit wird daher versucht, das Problem mithilfe von deterministischen Algorithmen zu lösen. Wesentliches Ziel ist die Implementierung eines Systems zur Kategorisierung der vorliegenden Kinect-Bewegungsdaten. Dieses System wird detailliert beschrieben und anschließend evaluiert. Dabei soll *hierarchisches Clustering* mithilfe des *Dynamic Time Warping (DTW)*-Algorithmus eingesetzt werden. Außerdem wird die Frage beantwortet, welches Vorwissen benötigt wird, um das Verfahren einsetzen zu können und welche Attribute zur Analyse interessant sind (z.B. Laufpfade oder Engaged-Werte).

2 Grundlagen und Problembeschreibung

Bevor näher auf die verwendeten Algorithmen eingegangen wird, werden grundlegende Aspekte erläutert. Dabei werden neben einigen Interaktionsmodellen vor Wandbildschirmen auch die eingesetzte Sensorik und die Struktur des Datensatzes beschrieben. Zudem erfolgt abschließend eine ausführliche Problembeschreibung.

2.1 Kategorien der Interaktion mit Wandbildschirmen

Interaktive digitale Medien sind in der Öffentlichkeit immer präsenter. Deshalb wird es für Wandbildschirme immer schwieriger die Aufmerksamkeit von Passanten zu erregen und sie zur Interaktion zu animieren. Diese Herausforderungen können nicht einfach durch verbesserte Hardware oder attraktivere Displays gelöst werden. Stattdessen muss ein besseres Verständnis von Menschen und deren Technologienutzung geschaffen werden (Wouters et al., 2016). *Ambient Displays* sind große, interaktive Bildschirme im (halb-) öffentlichen Raum, mit denen Nutzer interagieren können. Es handelt sich meist um ästhetisch ansprechende Displays die Personen mit Informationen versorgen (Mankoff et al., 2003). Eine Kategorisierung der Interaktion von Personen mit solchen Wandbildschirmen kann das Verständnis des Verhaltens verbessern. Dazu existieren verschiedenste *Audience Behaviour-Interaktionsmodelle*, wovon im Folgenden zwei näher beschrieben werden.

Das *Audience Funnel Modell* beschreibt, wie Menschen sich um ein großes öffentliches Display versammeln und von Beobachtern zu Interagierenden mit dem System, und anschließend wieder zu Beobachtern werden. Menschen neigen dazu verschiedene Phasen der Interaktivität zu durchlaufen, bevor sie direkt mit dem System interagieren (Mai & Hußmann, 2018; Wouters et al., 2016). Die einzelnen Phasen des *Audience Funnel* werden in Abbildung 2.1 gezeigt. Eine der Aufgaben eines Wandbildschirms ist es also Aufmerksamkeit auf sich zu ziehen und den Nutzer zu motivieren mit dem System zu interagieren (Mai & Hußmann, 2018). Mai und Hußmann (2018) verweisen darauf, dass *Ambient Displays* in der Öffentlichkeit nicht unbedingt der zentrale Punkt der Aufmerksamkeit sind, da vorbeigehende

gehende Personen eigene intrinsische Ziele verfolgen. Die Herausforderung für Entwickler ist es die Systeme so zu gestalten, dass sie Aufmerksamkeit erregen, sich aber gleichzeitig nicht gezwungen in den Mittelpunkt stellen.

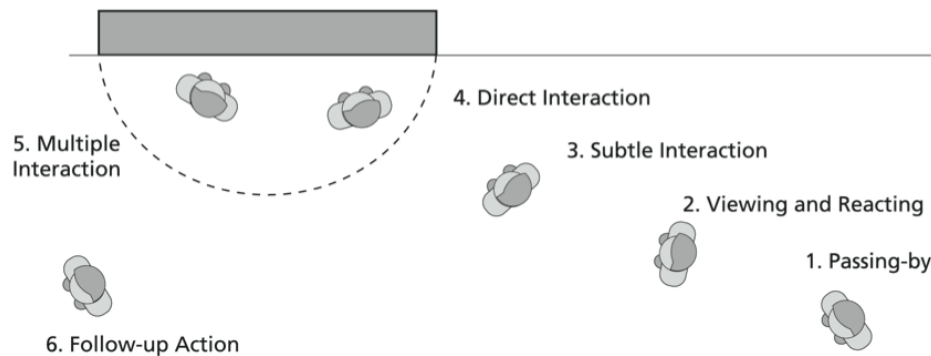


Abbildung 2.1: Audience Funnel Framework. Abbildung aus Mai und Hußmann (2018).

Ein zweites Modell wird durch den bereits erwähnten *Honeypot-Effekt* beschrieben. Er zeigt, dass Individuen unabhängig von Belohnungen, Bestrafungen oder sozialem Wettbewerb von der reinen Präsenz oder den Aktivitäten anderer beeinflusst werden. In der HCI wird dies meist erkennbar, indem Passanten sich einem System nähern und überlegen, ob sie mit ihm interagieren sollen, nachdem sie anderen Menschen dabei zugesehen haben (Wouters et al., 2016).

Eine Einordnung der Bewegungsdaten in die Kategorien solcher Modelle und eine weiterführende Analyse der Bewegungen kann Aufschluss über das Verhalten von Menschen vor interaktiven Bildschirmen geben. Wie bereits erwähnt ist eine Kategorisierung des vorliegenden Kinect-Datensatzes aufgrund der großen Datenmenge nicht manuell realisierbar. Im Folgenden werden die Struktur des Datensatzes und die Grundlagen der verwendeten Sensorik beschrieben. Aufbauend darauf werden Überlegungen angestellt, wie eine Implementierung zur Automatisierung der Kategorisierung aussehen kann.

2.2 Spezifikation der Kinect

(Tölgyessy et al., 2021) verweisen darauf, dass der Xbox 360 Kinect-Sensor eine „Revolution“ im Bereich der erschwinglichen 3D-Erkennungssensorik war. Ursprünglich war er für die Videospiel-Industrie gedacht. Schon bald wurde er aber auch für wissenschaftliche Experimente genutzt. In späteren Jahren folgten weitere Iterationen der Kinect (Tölgyessy et

al., 2021). Im vorliegenden Datensatz des *HoPE-Projekts* kam die Kinect v2 für Xbox One zum Einsatz. Diese Sensorik stellt Farbbilder einer Rot-Grün-Blau (RGB) Kamera, Tiefenbilder einer Tiefenkamera und Audiodateien verschiedener Mikrofone zur Verfügung (Microsoft, 2014). Besonders die Tiefenkamera hilft zuverlässige Ergebnisse bei der Erkennung von Menschen vor *Ambient Displays* zu erzielen. Li et al. (2014) fassen es wie folgt zusammen. Die kompakte Größe, die Benutzungsfreundlichkeit, die stark vereinfachte Hintergrund-Subtraktion im Vergleich zu anderer Sensorik, sowie die hohe Genauigkeit und die hohe Bildrate machen Tiefenkameras zu einer attraktiven Lösung für ein breites Spektrum an Anwendungen. Die Kinect v2 verwendet dabei den Ansatz der kontinuierlichen Wellenintensitätsmodulation, der häufig bei Time-of-Flight (ToF)-Tiefenkameras zum Einsatz kommt. Dabei wird das Licht einer Lichtquelle von Objekten im Sichtfeld der Kamera zurückgestreut und die Phasenverzögerung zwischen dem emittierten und dem reflektierten Licht gemessen. Diese Phasendifferenz wird für jedes Pixel im Bildfeld in einen Entfernungswert umgerechnet (Tölgyessy et al., 2021). Der Sensor kann Tiefenbilder mit einer Auflösung von 512 x 424 Pixeln und gewöhnliche Farbbilder mit 1920 x 1080 Pixeln aufnehmen (Marin et al., 2019). Bei der Kinect v2 können bis zu sechs Personen erfasst werden. Dabei wird die Lage von 25 Skelettpunkten, sowie verschiedene Gesichtsattribute erfasst (Microsoft, 2014). Abbildung 2.2 zeigt eine Übersicht dieser Punkte.




Abbildung 2.2: Skelettpunkte der Kinect v2. Abbildung von Microsoft (2014).

2.3 Struktur des vorliegenden Datensatzes

Zur Evaluation des implementierten System dienen verschiedene Teilmengen des Kinect-Datensatzes des *HoPE-Projekts*. Hierfür wurden im Jahr 2017 für 18 Wochen *Ambient Dis-*

plays mit Kinect v2 Systemen ausgestattet. Zu erwähnen ist zudem, dass das entwickelte Tool zur Auswertung auch mit anderen Datensätzen funktionieren soll.

Eine Auswertung des Datensatzes ergab, dass dieser 97.626 Records beinhaltet (Temiz, 2022). Dabei enthält jeder mehrere sogenannte Frames. Dabei handelt es sich um Momentaufnahmen der Kinect-Sensorik. Falls sich mehrere Menschen gleichzeitig im Sensorbereich befinden, erhält jede Person eine eindeutige Identifikationsnummer und der Record wird in mehrere Frames unterteilt. Dabei entspricht ein Frame der Momentaufnahme einer Person. Zu jedem Record liegen verschiedene Dateien vor, die jeweils den Zeitstempel in Kombination mit einem geeigneten Postfix als Dateinamen tragen. Tabelle 2.1 zeigt die Attribute der Datei *timestamp.txt*. Diese Attribute werden in der Textdatei durch drei Rauten ('###')

Attributname	Beschreibung
Zeitstempel	Zeitpunkt der Aufnahme
KinectId	Skelett-Identifikationsnummer des Framework
RecordId	Identifikationsnummer des Records
BodyIndex	Identifikationsnummer der Person
BodyCount	Anzahl der erfassten Personen
Happy	Person ist glücklich
Engaged	Person zeigt Interesse
WearingGlasses	Person trägt eine Brille
LeftEyeClosed	Person hat das linke Auge geschlossen
RightEyeClosed	Person hat das rechte Auge geschlossen
MouthOpen	Person hat den Mund geöffnet
MouthMoved	Person bewegt den Mund
LookingAway	Person schaut nicht zur Kinect
Body.HandLeftState	Zustand der linken Hand
Body.HandRightState	Zusand der rechten Hand
x	x-Koordinate des Skelettpunkts SpineShoulder
y	y-Koordinate des Skelettpunkts SpineShoulder
z	z-Koordinate des Skelettpunkts SpineShoulder
Distance	Distanz zwischen Kinect und Skelettpunkt SpineShoulder

Tabelle 2.1: Attribute des Datensatzes.

voneinander abgegrenzt. Ein konkreter Frame aus dem Datensatz kann Abbildung 2.3 entnommen werden.

```
2017-04-10 07:41:53.943 +02:00 ### 72057594038063128 ### 1341053376 ###  
### 1 ### 1 ### No ### Maybe ### Unknown ### No ### No ###  
No ### Yes ### Maybe ### Unknown ### Closed ### 0,1074784  
### 0,2451882 ### 4,18441 ### 4,19296454679429
```

Abbildung 2.3: Frame aus dem Datensatz.

Da die Anordnung und das Vorhandensein dieser Attribute je nach Version des Datensatzes abweichen kann, sollen diese in der Implementierung manuell konfigurierbar sein. Die Datei *timestamp_bodies.txt* enthält für jeden Frame die Position aller 25 Skelettpunkte. *timestamp_summary.txt* zeigt eine kurze Zusammenfassung des Records, welche gut menschenlesbar ist. *timestamp.xef* kann genutzt werden, um die Aufnahme in der Anwendung Kinect Studio zu visualisieren. Letztlich sind die Einträge sogenannte *TSD*. Bei diesem Datentyp handelt es sich um geordnete Sequenzen von Datenpunkten, die über eine gewisse Zeit hinweg aufgenommen wurden. Oft in regelmäßigen Abständen (Ali et al., 2019). Insgesamt befinden sich im Datensatz 34.687.630 Frames (Temiz, 2022). Diese Anzahl bestätigt erneut die Notwendigkeit eines Software-Tools zur Auswertung. Um aussagekräftige Ergebnisse zu erhalten lohnt es sich gegebenenfalls mit Teilmengen des Datensatzes zu arbeiten. So liefern beispielsweise Records mit weniger als zwei Sekunden zu wenig Information für Erkenntnisse über das Interaktionsverhalten. Je nach Fragestellung kann es ebenfalls lohnenswert sein Records mit einer, zwei oder mehreren Personen gesondert zu betrachten.

2.4 Problembeschreibung

Es gibt verschiedene Möglichkeiten sich der Kategorisierung von Bewegungsdaten zu nähern. So kann beispielsweise *Maschine Learning* eingesetzt werden. Dieser Ansatz wird derzeit ebenfalls im Rahmen des HoPE-Projekts erforscht (Plischke, 2022). In dieser Bachelorarbeit werden hingegen *deterministische Algorithmen* genutzt. Durch sie kann die Implementierung eines Kategorisierungssystems verhältnismäßig einfach gehalten werden. Aghabozorgi et al. (2015) verweisen zudem darauf, dass die Verwendung von Methoden wie Maschine Learning (*supervised*), im Falle von großen Datensätzen zu Problemen führen kann. Deterministische Cluster-Algorithmen sollten bei großen Datenmengen weniger Probleme bereiten (*unsuper-*

vised).

Beim vorliegenden Kinect-Datensatz handelt es sich ebenfalls um eine große Datenmenge. Die einzelnen Records müssen daher automatisiert bearbeitet werden. Ziel der Verarbeitung ist es möglichst sinnvolle *Cluster* zu erhalten. Um die Gemeinsamkeiten zweier Aufnahmen zu berechnen, wird eine geeignete Vergleichsfunktion benötigt. Die Wahl dieser Funktion ist wichtig für den Erfolg des *Clusterings* (Warren Liao, 2005). Zu beachten ist zudem, dass die Bewegungsaufnahmen durch *TSD* beschrieben werden. Werden hier herkömmliche Distanzmetriken, wie die Euklidische-Distanz verwendet kann dies zu Problemen führen und die Aussagekraft des Vergleichs verringern. Es kann vorkommen, dass verschiedene Personen die gleiche Bewegung unterschiedlich schnell, oder zeitlich versetzt ausführen. Gegebenenfalls weisen die Datenreihen bei der gleichen Bewegung daher sogar eine unterschiedliche Anzahl an Frames auf. Abbildung 2.4 zeigt ein exemplarisches Szenario. Die Kurven weisen ähnliche Segmente auf. Sie sind allerdings unterschiedlich lang und die Ähnlichkeiten treten zu unterschiedlichen Zeitpunkten auf. Mit der bekannten euklidischen Distanz ist das Ergebnis hier nicht aussagekräftig und der letzte Punkt der Reihe kann gar nicht zugordnet werden. Um dieses Problem zu lösen ist eine elastische Metrik nötig, die besser mit zeitlichen Verschiebungen umgehen kann (Aghabozorgi et al., 2015).




Abbildung 2.4: Zuordnung der Messpunkte zweier Datenreihen.

Das Clustering soll mithilfe von *hierarchischem Clustering* durchgeführt werden, welches in Abschnitt 3.1 beschrieben wird. Das Verfahren ist für die vorliegenden Daten gut geeignet, da es erlaubt TSD unterschiedlicher Länge zu clustern. Zudem muss die Anzahl der zu bildenden Cluster nicht im Voraus definiert werden, wie dies etwa bei *K-Means* der Fall ist (Aghabozorgi et al., 2015). Es ist in diesem Kontext nicht zielführend die Clusteranzahl zuvor zu definieren, da die Arbeit darauf abzielt, mehr Erkenntnis über mögliche sinnvolle Cluster

zu gewinnen. Statt die Anzahl vorzugeben, wird ein Threshold definiert der angibt, ab wann zwei Cluster nicht mehr zusammengeführt werden soll, weil die Differenz zwischen ihnen zu groß ist. Als geeignete Distanz-Metrik wird dabei *DTW* verwendet (Abschnitt 3.2). Hier ist eine Mehrfachzuordnung von Punkten möglich. Diese können so verbunden werden, dass die Kosten minimal sind. Dies erlaubt eine Zuordnung ähnlicher Muster in den Daten auch wenn sie zeitlich verschoben sind und ist daher gut für unsere Problemstellung geeignet.

3 Clustering von Bewegungsdaten mittels Dynamic Time Warping

Nach den einführenden Bemerkungen in Kapitel 1 und Kapitel 2 werden nun die eingesetzten deterministischen Algorithmen näher beschrieben. Die Grundlagen der Verfahren werden erläutert und an einem Beispiel veranschaulicht. Ein Einblick in verwandte Arbeiten (Abschnitt 3.4) vertieft das Verständnis weiter. Abschließend wird auf zu beachtende Besonderheiten des Kinect-Datensatzes eingegangen.

3.1 Hierarchisches Time-Series Clustering

Clustering kann genutzt werden, um große Datensätze zu kategorisieren, wenn keine Informationen zu den Kategorien vorliegen (Aghabozorgi et al., 2015). Ziel ist es, eine Struktur in den vorliegenden Daten zu finden, indem Elemente anhand eines festgelegten Vorgehens in homogene Gruppen einsortiert werden. Dabei sollen die Unterschiede bei Elementen der gleichen Gruppe möglichst gering und bei Elementen verschiedener Gruppen möglichst groß sein (Aghabozorgi et al., 2015; Warren Liao, 2005). Bei n Datenpunkten erzeugt ein *Clustering* k Partitionen des Datensatzes. Jede Partition entspricht dabei einem *Cluster*, dass mindestens ein Objekt enthält. Beim *Clustering* sind besonders die Wahl des Clustering-Algorithmus und der Methode zur Bestimmung der Ähnlichkeit von zwei Datenreihen von Bedeutung (Warren Liao, 2005). Letzteres wird DTW gelöst. Das Verfahren wird in Abschnitt 3.2 beschrieben. Als Clustering-Vorgehen kann das sogenannte *hierarchical Clustering* genutzt werden. Dieses funktioniert, indem Datenobjekte in einen Baum von Clustern eingeteilt werden. Bei agglomerativen Vorgehen wird ein *bottom-up* Ansatz verfolgt. Jedes Objekt ist daher zunächst ein eigenes Cluster. Dann werden schrittweise Cluster zusammengeführt, bis alle Objekte im selben Cluster sind, oder eine Terminierungsbedingung erfüllt ist (Warren Liao, 2005). In jedem Iterationsschritt werden dabei die beiden Cluster zusammengeführt, die die geringste Differenz zueinander aufweisen. Die Terminierungsbedingung ist bei uns das Überschreiten

des vordefinierten Thresholds.

Im Fall des Kinect-Datensatzes liegen die Daten als TSD vor. TSD zu kategorisieren findet in vielen wissenschaftlichen Gebieten Anwendung, um Muster zu finden. Sie erlauben es wichtige Informationen aus großen Datensätzen zu extrahieren. TSD sind dynamische Daten, weil sich die Attributwerte mit der Zeit verändern. Diese Sammlungen von Werten können aber auch als ein einziges Objekt betrachtet werden. Das Kategorisieren von derartigen Objekten kann bei der Detektion relevanter Muster helfen (Aghabozorgi et al., 2015). Die meisten bestehenden Cluster-Algorithmen können auf diesen Datentypen zugeschnitten werden. So auch das hierarchische Clustering. Der größte Unterschied ist wie bereits erwähnt, dass die Distanz-/ Ähnlichkeitsmetrik angepasst werden muss, um sinnvoll bei TSD genutzt werden zu können. Ein Vorteil ist, dass hierarchisches Clustern bei der Verwendung von DTW nicht auf Datenreihen der gleichen Länge beschränkt ist (Warren Liao, 2005).

3.2 Dynamic Time Warping Algorithmus

Der *DTW Algorithmus* kann als Distanz-Metrik beim hierarchischen Clustern genutzt werden. Hier sind *one-to-many* oder *one-to-none* Beziehungen zwischen Datenpunkten möglich. Man bezeichnet das Vorgehen daher auch als eine *elastische Metrik*. Sie kann gut mit zeitlichen Verschiebungen und unterschiedlich langen Datenreihen umgehen (Aghabozorgi et al., 2015).

In der Literatur findet man viele Erläuterungen des DTW-Algorithmus. Beispielsweise in Mohammadzade et al. (2021), Warren Liao (2005), Aghabozorgi et al. (2015) oder Yu und Xiong (2019). Im Folgenden soll der Algorithmus ebenfalls erläutert werden. Das Ziel ist die Zuordnung verschiedener Signale, die im Verlauf der Zeit ähnliche Muster aufweisen. Diese Muster treten zu unterschiedlichen Zeiten oder in unterschiedlichen Raten auf. Um die Zuweisung zueinander zu erreichen muss ein Signal gegebenenfalls lokal gestreckt oder gestaucht werden. Durch *dynamisches Programmieren* kann eine Korrespondenz zwischen den Zeitindizes zweier Signale gefunden werden, sodass die Summe der Distanzen zwischen den beiden Signalen minimal ist (Mohammadzade et al., 2021).

Seien $Q = q_1, q_2, \dots, q_i, \dots, q_n$ und $R = r_1, r_2, \dots, r_j, \dots, r_n$ zwei Signale die durch DTW ausgerichtet werden sollen, sodass die Differenz zwischen ihnen minimal ist. Dafür wird eine $n \times m$ Matrix M gebildet, wobei das Element (i, j) die Distanz $d(q_i, r_j)$ zwischen zwei Punkten q_i und r_j enthält. Hierfür wird im Normalfall die euklidische Distanz genutzt (Warren Liao, 2005). Allerdings sind auch andere Funktionen denkbar. In der Zelle $(0, 0)$ enthält die Matrix

den Wert 0 und für die übrigen Zellen der Spalte und Zeile 0 wird jeweils der Wert unendlich angenommen. Das Verfahren kann auf einfache Weise auf mehrdimensionale TSD angepasst werden. In diesem Fall sind die zu minimierenden Kosten die Summe der Distanzen zwischen den korrespondierenden Werten der beiden Datenreihen (Mohammadzade et al., 2021). Ein *Warping Pfad* $W = w_1, w_2, \dots, w_k, \dots, w_K$ in dem $\max(m, n) \leq K \leq m + n - 1$ gilt, ist eine Reihe von Matrixelementen die drei Bedingungen erfüllen:

- Grenzbedingungen
- Kontinuität
- Monotonität

Die Grenzbedingungen fordern, dass die Startzelle des Warping Pfads in der Matrix eine andere ist als die Zielzelle. Dabei gilt: $w_1 = (m, n)$ und $w_k = (0, 0)$. Aufgrund der Kontinuität sind nur Schritte in angrenzende Zellen erlaubt. Die Monotonitätsbedingung zwingt den Warping Pfad dazu, sich monoton in der Zeit zu bewegen.

Mit Hilfe von dynamischer Programmierung können die Matrixeinträge von $M_{(0,0)}$ ausgehend berechnet werden, indem wiederholt die folgende Gleichung ausgewertet wird: $M_{(i,j)} = d(q_i, r_j) + \min \{M_{(i-1,j-1)}, M_{(i-1,j)}, M_{(i,j-1)}\}$. Sie definiert den kumulativen Abstand als die Summe aus dem Abstand des aktuellen Elementes und dem Minimum der kumulativen Abstände der benachbarten Elemente (Warren Liao, 2005). Der Pfad mit der minimalen Distanz ist von Bedeutung. Er kann mit $d_{DTW} = \min(\frac{\sum_{k=1}^K w_k}{K})$ berechnet werden.

3.3 Veranschaulichendes Beispiel

Zur Veranschaulichung soll nun das Vorgehen anhand von vier Datenreihen durchgeführt werden. Seien $R_1 = (0, 1, 1, 2, 2, 1, 1)$, $R_2 = (0, 1, 1, 1, 2, 2, 1, 1)$, $R_3 = (1, 1, 0, 1, 2, 2, 1, 1)$ und $R_4 = (2, 2, 1, 2, 2, 2)$ gegeben. Die Kosten können berechnet werden, indem die Kostenmatrix aufgestellt und der Warping Pfad berechnet wird (Abschnitt 3.2). Für die Berechnung der Kosten zwischen R_1 und R_2 ergibt sich beispielsweise die in Tabelle 3.1 gezeigte Matrix mit hervorgehobenem Warping Pfad. Tabelle 3.2 zeigt die gerundeten Kosten zwischen den einzelnen Reihen. Da R_1 und R_2 zusammen die geringsten Kosten haben bilden sie das erste Cluster C_1 . Um dessen Wertreihe zu erhalten werden die Attributwerte paarweise addiert und die Summe anschließend halbiert. Dabei kann anhand des Warping Pfads abgelesen werden, welche Werte zusammengehören. Die Bildung der Paare entspricht also

0	∞	∞	∞	∞	∞	∞	∞	∞
∞	0	1	2	3	5	7	8	9
∞	1	0	0	0	1	2	2	2
∞	2	0	0	0	1	2	2	2
∞	4	1	1	1	0	0	1	2
∞	6	2	2	2	0	0	1	2
∞	7	2	2	2	1	1	0	0
∞	8	2	2	2	2	2	0	0

Tabelle 3.1: Kostenmatrix mit hervorgehobenem Warping Pfad.

Reihen	Kosten
R_1, R_2	0
R_1, R_3	1.56
R_1, R_4	2.88
R_2, R_3	2.89
R_3, R_4	2.67

Tabelle 3.2: Erster Durchlauf der Kostenberechnung.

der Zuordnung mit den geringsten Kosten. So ergibt sich $C_1 = (0, 1, 1, 1, 2, 2, 1, 1)$. Falls mehrere verschiedene Attribute berücksichtigt werden kann für sie eine kombinierte Matrix erstellt werden, indem für jedes Attribut eine Matrix erstellt wird und deren Mittelwert in eine neue Matrix geschrieben wird. Da all diese Matrizen das selbe Format haben, ist dies problemlos möglich. Der Warping Path kann dann an dieser kombinierten Matrix abgelesen werden. Die Bildung der Paare erfolgt entsprechend. Es sollte ein *Threshold* definiert werden, der angibt, ab wann die Kosten zu groß sind, um die beiden Datenreihen zu einem Cluster zusammenzuführen. Ein sinnvoller Wert hängt dabei vom vorliegenden Datensatz ab. Sei dieser Threshold im Folgenden $t = 2$. Nun werden die Schritte wiederholt, wobei C_1 als eine einzelne neue Datenreihe betrachtet wird. Dabei ergeben sich die Kosten in Tabelle 3.3. Nun haben C_1 und R_3 die geringsten Kombinationskosten. Da die Kosten geringer sind als der Threshold kann ein neues Cluster gebildet werden. Es ergibt sich $C_2 = (0.5, 1, 0.5, 1, 2, 2, 1, 1)$. Damit können die neuen Kosten berechnet werden, welche in Tabelle 3.4 dar-

Reihen	Kosten
C_1, R_3	1.56
C_1, R_4	2.89
R_3, R_4	2.67

Tabelle 3.3: Zweiter Durchlauf der Kostenberechnung.

gestellt sind. Da die berechneten Kosten den zuvor definierten Threshold übersteigen wird

Reihen	Kosten
C_2, R_4	2.78

Tabelle 3.4: Dritter Durchlauf der Kostenberechnung.

kein neues Cluster mehr gebildet und wir sind am Ende unserer Berechnungen angekommen. Abbildung 3.1 veranschaulicht die gebildeten Cluster.




Abbildung 3.1: Graphische Veranschaulichung der gebildeten Cluster.

3.4 Related Work Analyse

DTW kommt in vielen Arbeiten als Distanz-Metrik zum Einsatz. Im Folgenden wird eine Auswahl dieser Veröffentlichungen beschrieben.

Wahyuni et al. (2021) stellen ein Erkennungssystem für Gesten vor. Dabei wird eine

Kinect-Kamera genutzt, um die Bewegungen aufzuzeichnen. Es kommt eine Form des DTW-Algorithmus zum Einsatz, um die Gesten zu erkennen. Für den Vergleich werden die x- und y-Koordinaten von sechs Körperpunkten genutzt. Dabei liegen zu jeder bekannten Bewegung jeweils Referenzwerte für den Vergleich mit den aktuellen Werten vor. Für die Entscheidung, ob eine betrachtete Bewegung zu einer Kategorie gehört oder nicht sind die Kosten entscheidend. Es wird ein Threshold definiert. Liegen die aktuellen Kosten über diesem wird die Bewegung verworfen. Falls sie geringer sind wird der Ablauf in die Kategorie einsortiert. Die Definition von geeigneten Threshold-Werten für die Differenz zwischen Datenreihen wird auch im späteren Verlauf dieser Arbeit relevant. So kann entschieden werden, ob Cluster weiter zusammengeführt werden sollten oder nicht. Yu und Xiong (2019) nutzten DTW, um physische Rehabilitationsübungen mithilfe eines Kinect-Sensors zu bewerten. Dabei wird zunächst die Ähnlichkeit zwischen den TSD des Nutzers und des Trainers berechnet. Als Eingabeattribute werden hier acht sogenannte Knochenvektoren des menschlichen Skeletts und dessen Körperorientierung verwendet. Ein Knochen der zwischen zwei Gelenkpunkten liegt wird als 3D-Vektor im Raum interpretiert. Die Summe der Winkeldifferenzen zwischen allen korrespondierenden Knochenvektoren der beiden Bewegungsreihen dient als Distanzmetrik. Die Ergebnisse zeigen, dass DTW effektiv eingesetzt werden kann, um automatisiert Bewegungsabläufe mit Vorlagen zu vergleichen und diese somit zu bewerten. Im Kontext der Interaktion mit Wandbildschirmen werden andere Eingabewerte interessant sein als hier. Deshalb müssen geeignete Werte für unsere Szenarien elaboriert werden. Mohammadzade et al. (2021) nutzen TSD-Informationen für eine Überwachung von alltäglichen menschlichen Aktivitäten. Jede Aktion wird durch eine mehrdimensionale Time-Series repräsentiert. Dabei entspricht eine Dimension jeweils der Position eines Skelettpunkts im Verlauf der Zeit. Im vorliegenden Ansatz wird jeder Bewegungsklasse genau eine Referenzbewegung zugeordnet. Die Daten werden entsprechend mit diesen Referenzen verglichen. Dadurch sind viel weniger Vergleiche nötig als bei anderen DTW-Methoden, wodurch die Rechenkomplexität abnimmt. Allerdings sind dafür vordefinierte Klassen mit teils künstlich erzeugten Beispielbewegungen nötig. Wesentliches Ziel dieser Bachelorarbeit ist es allerdings dazu beizutragen neue Informationen über mögliche Interaktionsverhalten mit interaktiven Wandbildschirmen zu gewinnen. Eine Definition im Voraus ist für dieses Szenario nicht zielführend. Hautamaki et al. (2008) vergleichen experimentell einige Time-Series Clustering-Verfahren mit DTW als Distanzmetrik. Hierarchisches Clustering wird hier agglomerativ implementiert. Das bedeutet, dass zunächst alle Records als eigenes Cluster initialisiert werden. Durch iterierte Anwendung

von Merge-Operationen werden schrittweise zwei Cluster zusammengeführt, die eine geringe Distanz in den TSD aufweisen. Hautamaki et al. (2008) prüfen die Zuverlässigkeit anhand mehrerer Experimente. Unter anderem mit Sprachdaten, die ebenfalls zu den TSD gehören. Die Evaluation zeigt, dass hierarchisches Clustering in Kombination mit DTW erfolgreich eingesetzt werden kann.

3.5 Einsatz im Kontext von Kinect-Bewegungsdaten

Wie bereits erwähnt handelt es sich bei den vorliegenden Daten um TSD. Warren Liao (2005) und Aghabozorgi et al. (2015) weisen darauf hin, dass besonders die verwendete Distanz-/Ähnlichkeitsmetrik entscheidend ist, um diesen Datentyp sinnvoll in Kategorien einteilen zu können. Hierarchisches Clustering in Kombination mit DTW scheint ein vielversprechender Ansatz zu sein. Da die Daten in Textdateien vorliegen ist eine Komponente im System nötig, die diese Informationen ausliest und in geeigneten Objekten der genutzten Programmiersprache abspeichert. Besonders von Bedeutung ist zudem die Wahl geeigneter Attribute. Die Daten enthalten viele Werte die mehr oder weniger interessant für die Kategorisierung sein können. Die Laufwege oder Engagement-Werte sind beispielsweise relevanter als die Tatsache, ob eine Person Brillenträger ist oder nicht. Idealerweise sollte die Wahl der genutzten Attribute vom Nutzer der Anwendung definiert werden können. So kann das Tool effektiv genutzt werden, um nach wiederkehrenden Abläufen in den Daten zu suchen. Des weiteren stellt sich die Frage, ab wann keine weitere Clusterbildung mehr stattfinden soll. Dazu muss ein geeigneter Threshold definiert werden. Zudem ist die große Menge der Daten zu erwähnen. Aghabozorgi et al. (2015) weist darauf hin, dass DTW weniger performant ist als herkömmliche Metriken wie die euklidische Distanz. Gegebenenfalls müssen die Daten vor der Nutzung geeignet gefilter werden. Diese Filterung soll allerdings nicht Bestandteil dieser Bachelorarbeit sein.

4 Konzeption

Vor der eigentlichen Implementierung erfolgt nun eine Konzeption. Damit wird elaboriert, welche Anforderungen an die Software gestellt werden und wie die Implementierung erfolgen soll. Etwaige Ungereimtheiten und Probleme können so frühzeitig erkannt werden.

4.1 Anforderungsanalyse

Es soll ein System implementiert werden, welches Kinect-Bewegungsdaten mithilfe von hierarchischem Clustering und DTW als Distanzmetrik gruppiert. Dieses Tool kann im Rahmen des HoPE-Projekts genutzt werden, um große Datensätze auf wiederkehrende Bewegungsabläufe bei der Interaktion mit Wandbildschirmen zu untersuchen. Es gibt sogenannte *funktionale Anforderungen* und *nicht-funktionale Anforderungen*, die das System erfüllen muss. Letztere beinhalten beispielsweise Anforderungen zu Benutzbarkeit, Effizienz oder Portierbarkeit. Funktionale Anforderungen beschreiben hingegen die primären Features des Systems.

4.1.1 Nicht-funktionale Anforderungen

Bei der Wahl der Programmiersprache und verwendeten Frameworks existieren keine speziellen Vorgaben. Das Tool sollte allerdings ohne großen Installationsaufwand nutzbar sein und daher nach Möglichkeit eine stark verbreitete Programmiersprache nutzen. Bei der Implementierung fällt daher die Wahl auf Java in der Version 14. Dabei sollen auch keine externen Bibliotheken genutzt werden. An die Effizienz gibt es ebenfalls keine besonderen Anforderungen, da die Auswertung der Daten nur einmalig zu einem späteren Zeitpunkt erfolgt. Eine Echtzeitauswertung ist nicht geplant. Da zu lange Wartezeiten, aber die Nutzbarkeit des Tools einschränken, sollen berechnete Kosten in einer geeigneten Datenstruktur zwischengespeichert werden. So können im darauffolgenden Iterationsschritt viele Berechnungsschritte eingespart werden. Das Tool sollte durch wenige Anpassungen auch auf Datensätze anderer Tiefenkameras angewandt werden können. Um dieses Ziel zu erreichen, wird die Software von

Beginn an möglichst generisch entwickelt. Zu allen Bestandteilen des Tools existiert daher ein Interface. Bei Bedarf können so einfach neue Implementierungen, die den Anforderungen anderer Datensätze entsprechen, ergänzt werden.

4.1.2 Funktionale Anforderungen

Die Software kümmert sich um den Input. Ein Datensatz kann aus Textdateien eingelesen und in passenden Datenobjekten abgespeichert werden. Das Tool soll ein Clustering mittels hierarchischem Clustering wie in Abschnitt 3.1 beschrieben anbieten. Dabei ist der Threshold für das Mergen von zwei Clustern vom Nutzer konfigurierbar. Als Distanzmetrik wird DTW (Abschnitt 3.2) genutzt. Dabei ist konfigurierbar, welche Attribute des Datensatzes für den Vergleich genutzt werden. Zur Berechnung der Distanz zwischen zwei Punkten wird die euklidische Distanz verwendet. Allerdings können auch hier einfach weitere Funktionen ergänzt werden. Per Startparameter kann entschieden werden, welche dieser Funktionen für die Berechnung verwendet wird. Zudem besitzt das Output-Funktionalitäten. Die gefundenen Cluster werden in einer Textdatei aufgelistet. Jedes Cluster erhält einen eindeutigen Namen und eine Liste aller Records die zusammengeführt wurden. Für ein erleichtertes Verständnis der Cluster wird auch eine primitive Visualisierung der Cluster angeboten. Die starke Konfigurierbarkeit wird durch eine *config-file* erreicht, die der Nutzer beim Start der Anwendung übergeben kann. Tabelle 4.1 zeigt die Attribute.

4.2 Programmablauf

Im Folgenden wird der Programmablauf beschrieben.

1. Der Nutzer startet den *Clustering-Processor* und gibt als Startparameter den Pfad der *config-Datei* an.
2. Der *Processor* nutzt den *Config-Reader*, um die Werte der *Konfigurationsdatei* auszu-lesen und speichert diese ab.
3. Der *Processor* nutzt den *DataReader*, um den Datensatz einzulesen und legt die Informationen in geeigneten Objekten ab. Beim Kinect-Datensatz sind das die Implementierungen *RecordImpl* und *FrameImpl* der entsprechenden Interfaces.
4. Der *Processor* startet das Clustering durch den Aufruf der *cluster-Methode* der

Attributname	Beschreibung
inputPath	Pfad zum Datensatz.
outputPath	Pfad zum Ablegen der Output-Dateien.
separator	Trennzeichen zwischen den Attributen.
datasetType	Art des vorliegenden Datensatzes.
threshold	Grenzwert für das Zusammenführen von Clustern.
attributes	Vorhandene Attribute.
usedAttributes	Attribute, die zum Vergleich genutzt werden.
distanceFunction	Name der genutzten Distanzfunktion.
flipVisualization	Wahrheitswert, ob die Visualisierung gespiegelt wird.
attributeForBodyIdentification	Bezeichnung des Körperidentifikationsparameters.
skipFrames	Wahrheitswert, ob jeder zweite Frame ignoriert wird.

Tabelle 4.1: Attribute der Configuration-Datei.

HierarchicalClustering-Klasse. Zu Beginn entspricht jeder Record einem eigenen Cluster. Die *recordToCluster-Methode* ermöglicht eine Transformation.

5. Das Clustering nutzt die *DTW-Implementierung*, um paarweise die Kosten zweier Cluster zu berechnen.
6. Die beiden Cluster mit den geringsten Kosten werden zusammengeführt. Dazu wird ein neues *Cluster-Objekt* angelegt, das durch Kombination der beiden Cluster entsteht. Konkret wird eines der Cluster in das andere integriert. Beim integrierten wird ein boolescher Wert auf *false* gesetzt, damit das Cluster in späteren Berechnungsschritten nicht mehr beachtet wird. Dabei wird jeweils das Mittel der Attributwerte berechnet und abgelegt. Zudem werden die Cluster-Bestandteile abgespeichert. Bei allen Komponenten wird ebenfalls das *consider-flag* auf *false* gesetzt, damit sie bei zukünftigen Vergleichen nicht mehr berücksichtigt werden.
7. Schritte 5 und 6 werden so lange wiederholt, bis die geringsten Kosten den vom Nutzer definierten Threshold übersteigen.
8. Der *Processor* nutzt den *Cluster-Writer*, um alle Cluster der *clusters-Liste* in eine Ausgabedatei zu schreiben.

9. Die Anwendung terminiert.

4.3 Teilsysteme

Abbildung 4.1 kann das Paketdiagramm des Tools entnommen werden. Das Paket *model*

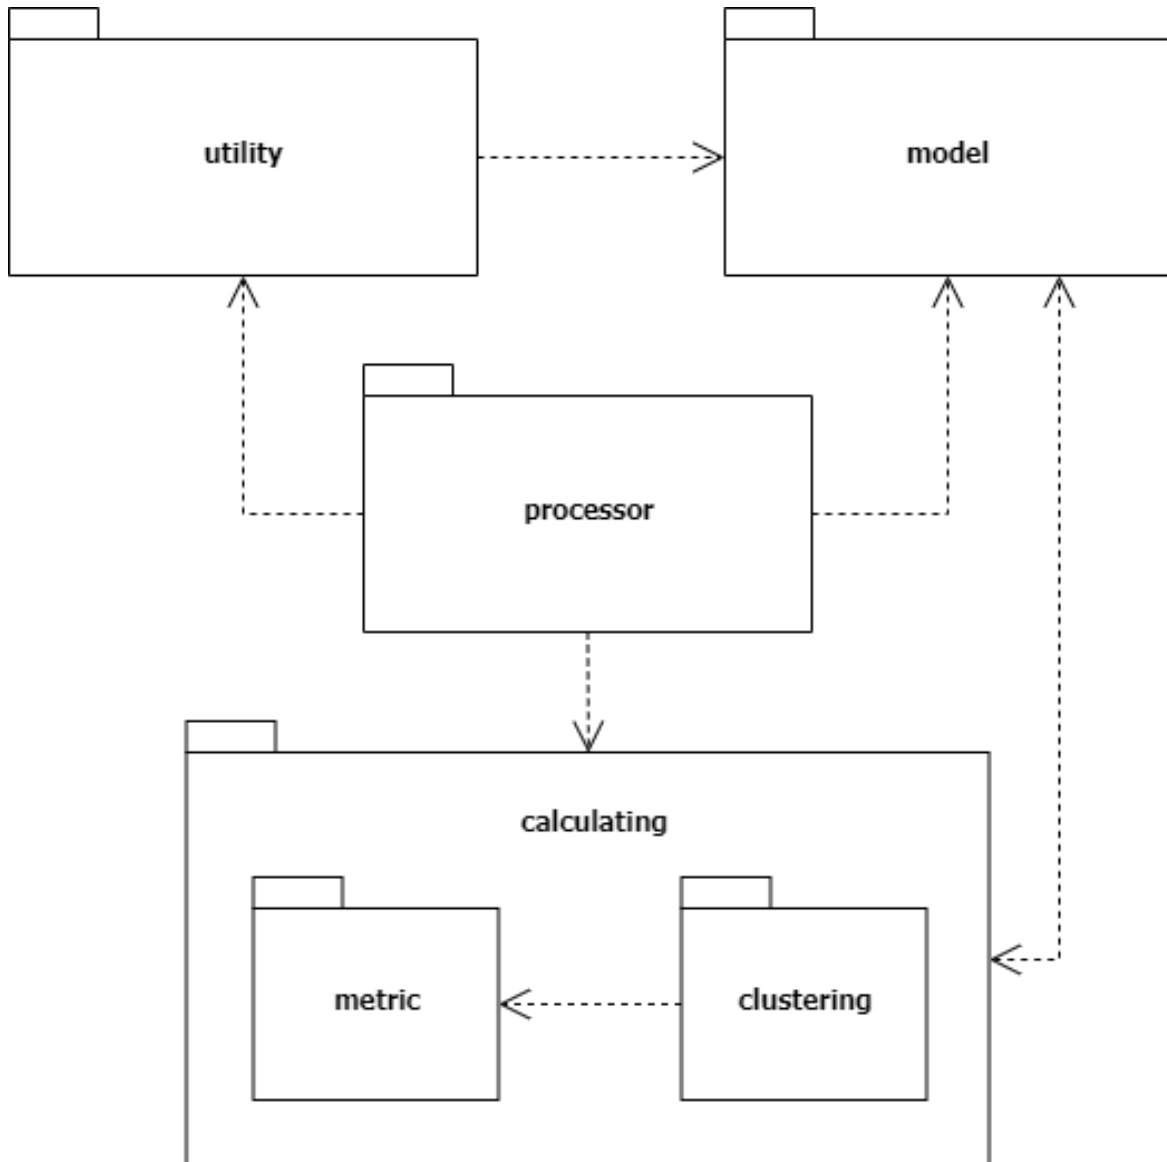


Abbildung 4.1: Paketdiagramm des Tools.

enthält die Interfaces für Cluster, Records und Frames. Außerdem jeweils geeignete Implementierungen dieser Interfaces für den Kinect-Datensatz. Bei Bedarf können hier bei späterer

Verwendung der Software weitere Implementierungen für andere Datensätze ergänzt werden. Im *utility*-Paket befinden sich Interfaces für Reader und Writer. Auch hier sind geeignete Implementierungen Bereitsgestellt. Konkret ein Reader für die Config-Datei, ein Reader für die Kinect-Daten und ein Writer für die gefundenen Cluster. Im Paket *calculating* befindet sich alles was für das Clustern der Daten benötigt wird. Es ist weiter untergliedert in *clustering* und *metric*. Letzteres liefert die Vergleichsmetrik für unser Clusterverfahren. Wieder liegen geeignete Interfaces vor, sodass die Anwendung bei Bedarf um weitere Metriken oder Clustering-Ansätze erweitert werden kann. Bereitsgestellt werden initial eine Implementierung mit hierarchischem Clustering und DTW als Metrik. Das Paket *processor* ist von zentraler Bedeutung. Hier wird die Funktionalität des Tools zusammengeführt. Zunächst werden die benötigten Reader Instanzen initialisiert. Mit ihnen werden die Daten eingelesen. Anschließend wird das Clustering gestartet und die Ergebnisse mithilfe des Writers geeignet in der Ausgabedatei gespeichert.

5 Implementierung

Wie bereits erwähnt erfolgt die Implementierung in Java. Damit für die Nutzung keine weiteren Installationen nötig sind, werden nur die Java-Standardbibliotheken zur Umsetzung genutzt. Der gesamte Source Code kann unter github.com/lzfs/tsprocessor abgerufen werden. In diesem Kapitel wird vertiefend auf die Struktur des Tools eingegangen. Zudem werden wichtige Aspekte der Implementierung betrachtet.

5.1 Aufbau

Der detaillierte Aufbau des Tools kann dem Klassendiagramm in Abbildung 5.1 entnommen werden. Dabei wurde aus Gründen der Übersichtlichkeit auf Konstruktoren, Getter- und Setter-Methoden verzichtet. Die wichtigsten Aspekte der Software werden im Folgenden beschrieben. Die grobe Struktur entspricht der aus Abschnitt 4.3. Zum Start der Anwendung ist ein Aufruf der *main-Methode* des *Processor* nötig. Dieser initialisiert zunächst geeignete *Reader*. Das *Reader-Interface* wird von den Klassen *ConfigReader* und *DataReader* implementiert. Der *ConfigReader* dient lediglich dazu die Werte der Config-Datei einzulesen. Dabei wird ein *Properties-Objekt* zurückgeliefert, mit dem auf die jeweiligen Werte zugegriffen werden kann. Der *DataReader* liest die Kinect-Daten ein. Ihm wird zunächst übermittelt, welche Attribute vorhanden sind, durch welches Zeichen sie voneinander abgetrennt sind und ob *Frames* übersprungen werden sollen, um die Performanz zu verbessern. Mit diesen Informationen können die Daten geeignet eingelesen und eine *RecordImpl-Liste* zurückgeliefert werden. Jede *RecordImpl* enthält dabei eine Liste von *FrameImpl*. Diese Datentypen sind die entsprechenden Implementierungen der Interfaces *Record* und *Frame*. Sie können für Kinect-Daten genutzt werden. Eine *FrameImpl* enthält jeweils eine Map mit ihren Attributen. Diese können mithilfe der *getValue-Methode* abgerufen werden. Ein weiterer Datentyp ist das *Cluster* und die zugehörige *ClusterImpl*. Cluster bestehen aus beliebig vielen, aber mindestens einer *RecordImpl*. Die Bestandteile werden in einer Liste gespeichert. Hier werden die Methoden *mergeWithCluster* und *mergeWithRecord* angeboten. Mit ihnen wird jeweils

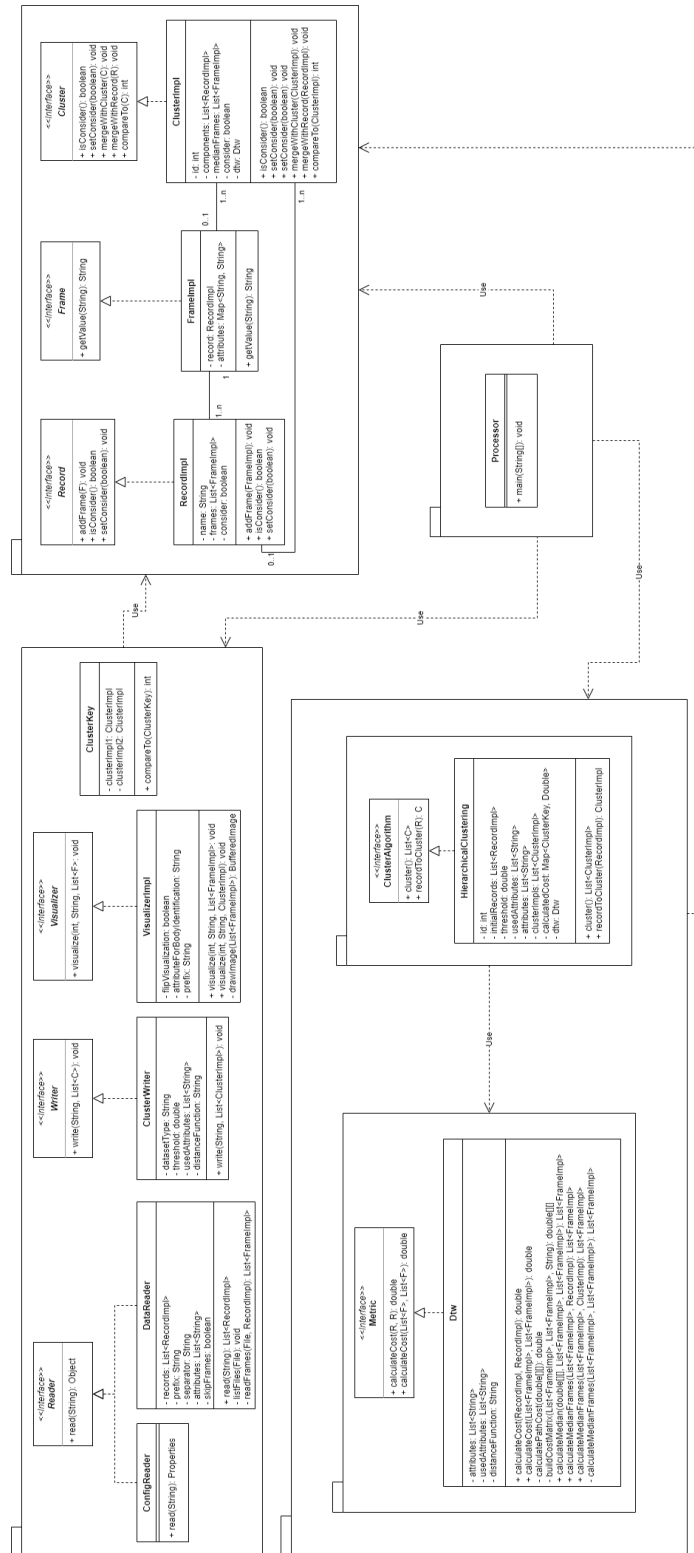


Abbildung 5.1: Klassendiagramm des Tools.

eine weitere Komponente in die *ClusterImpl* integriert. *ClusterImpls* haben außerdem eine eindeutige Identifikationsnummer und eine Liste der berechneten *FrameImpl-Mittelwerte* aller Komponenten. Zudem besitzen sie, genau wie die *RecordImpls*, einen Wahrheitswert der angibt, ob die *ClusterImpl* in zukünftigen Kombinationsschritten weiterhin beachtet werden soll. Alle genannten Interfaces können bei Bedarf geeignet für andere TSD-Datensätze implementiert werden. Nach dem Einlesen und Abspeichern der Daten startet der *Processor* das Clustering. Dazu wird eine Instanz von *HierarchicalClustering*, einer Implementierung von *ClusterAlgorithm*, erstellt. Das Objekt erhält dafür alle wichtigen Informationen, wie die initialen *RecordImpls*, den Threshold und die Attribute vom *Processor*. Da jede *ClusterImpl* am Anfang aus einer einzigen *RecordImpl* besteht, wird eine *recordToCluster-Methode* angeboten. Mit ihr kann jeder der initialen *RecordImpls* transformiert und anschließend in der *clusterImpl-Liste* abgelegt werden. Die *cluster-Methode* kümmert sich um den eigentlichen Cluster-Vorgang. Dabei nutzt sie zur Berechnung von Kosten eine Instanz der *Dtw-Klasse*. Sie implementiert das *Metric-Interface* und bietet daher die nötigen Methoden, um die Kosten zwischen zwei *RecordImpls*, beziehungsweise deren *FrameImpl-Listen* zu berechnen. Dabei kommt der in Abschnitt 3.2 beschriebene DTW-Algorithmus zum Einsatz. Um auch eine *ClusterImpl* mit einer *RecordImpls* vergleichen zu können bietet die Klasse zudem entsprechende *calculateMedianFrames-Methoden*, die aus mehreren *FrameImpl-Listen* eine neue erzeugt, indem die Werte mithilfe von DTW kombiniert werden. Das genaue Verhalten der Klassen *HierarchicalClustering* und *Dtw* wird in Abschnitt 5.2 näher betrachtet. Nach dem Ende der Berechnungen liegen die gefundenen *ClusterImpls* in der *clusterImpl-Liste* vor. Sie werden mit dem *ClusterWriter* geeignet in einer Textdatei abgespeichert. Zudem kann eine Visualisierung mithilfe der *VisualizerImpl* erfolgen. Die Klasse nutzt dazu einfache Java-AWT-Komponenten. Der Wahrheitswert *flipVisualization* gibt dabei an, ob die Werte in x-Richtung gespiegelt werden sollen. Dies ist nötig, da bei der Kinect das Koordinatensystem aus Nutzersicht erstellt wird. In der Visualisierung führt dies dazu, dass die aufgezeichneten Bewegungen spiegelverkehrt erscheinen. Der String *attributeForBodyIdentification* dient dazu, die unterschiedlichen Personen im *Record* korrekt darzustellen.

5.2 Codebeschreibung

Nach der Beschreibung des Ablaufs und der groben Struktur sollen nun wichtige Codeausschnitte des hierarchischen Clusterings und des DTW-Algorithmus beschrieben werden. Objekte der Klassen *ClusterImpl*, *RecordImpl* und *FrameImpl* werden in diesem Abschnitt

vereinfacht als Cluster, Record und Frame bezeichnet. Bei der Ausführung des Folgenden Codes wurden die Daten bereits eingelesen. Zudem wurde ein HierarchicalClustering-Objekt mit den nötigen Parametern erzeugt. Damit wird die cluster-Methode gestartet. Die Klasse HierarchicalClustering verfügt über eine clusterImpl-Liste, welche zunächst leer ist. Sie wird mit den initialen Clustern belegt, indem alle Records zunächst zu trivialen Clustern transformiert werden und anschließend der Liste hinzugefügt werden. Des Weiteren werden die nötigen Variablen für die Berechnung deklariert. Listing 5.1 zeigt diese Schritte. Der

```

1 // Initialize each record as a cluster and add it to the clusters list.
2 for (RecordImpl record : this.initialRecords) {
3     this.clusterImpls.add(this.recordToCluster(record));
4 }
5 double currentMinimumCost;
6 double cost;
7 int mergeCandidate1;
8 int mergeCandidate2;
```

Listing 5.1: Cluster-Methode: Initialisierung.

eigentliche Berechnungsablauf wird in Listing 5.2 gezeigt. Er befindet sich in einer Schleife die mindestens einmal ausgeführt wird. Sie läuft weiter, bis die geringsten gefundenen Kosten den Threshold übersteigen, oder nur noch ein einziges Cluster übrig ist. Die Merge-Kandidaten geben die Indizes der beiden Cluster mit den geringsten Kombinationskosten an. In jedem Durchlauf der while-Schleife werden die Werte der Kosten und die gewählten Merge-Kandidaten zurückgesetzt. Dazu werden standardmäßig das erste und zweite Cluster in der Liste und deren Kosten gewählt. Dann werden mittels der geschachtelten Schleifen paarweise die Cluster miteinander verglichen. Dabei werden nur Cluster in Betracht gezogen deren *consider-Wert* noch *true* ist. Außerdem darf es sich nicht zweimal um das gleiche Cluster handeln. Mithilfe der *calculatedCost-Map* wird geprüft, ob die Kosten für diese Kombination schon berechnet wurden. Falls ja werden sie wieder genutzt, falls nein werden sie neu berechnet. Als Schlüssel dient ein Objekt der bereits erwähnten *ClusterKey-Klasse*. Deren *equal-Methode* ist so definiert, dass *new ClusterKey(clusterImpl1, clusterImpl2).equals(new ClusterKey(clusterImpl2, clusterImpl1)) == true* gilt. Somit wird auch der symmetrische Fall betrachtet. Immer wenn eine Kombination gefunden wird, deren Kosten geringer sind als die bisherigen, werden die aktuellen Minimalkosten und die Merge-Kandidaten angepasst. Nach dem Vergleich aller Cluster, erfolgt die Kombination der beiden mit den geringsten

Kombinationskosten. Dies ist in Listing 5.3 zu sehen. Die beiden Cluster mit den geringsten Kombinationskosten wurden gefunden. Die zugehörigen Kosten sind in der Variablen *currentMinimumCost* abgelegt. Sind diese immer noch geringer als der definierte Threshold können die Kandidaten zusammengeführt werden. Dazu wird *mergeCandidate2* mit der Methode *mergeWithCluster* in *mergeCandidate1* integriert. Dabei wird der *consider*-Wert des *mergeCandidate2*-Clusters auf *false* gesetzt, da es in künftigen Schritten nicht mehr als eigenständige Einheit betrachtet werden soll. Abschließend müssen alle berechneten Werte mit *cluster1* aus der *calculateCost-Map* entfernt werden, da die aktuellen Werte aufgrund der neuen Komponente nicht mehr gültig sind. Die Kosten mit *cluster2* können ignoriert werden, da diese Cluster ohnehin nicht mehr betrachtet werden. In den oben gezeigten Clustering-Schritten wurden die Kosten mithilfe der *calculateCost-Methode* berechnet. Listing 5.4 zeigt diese. Für jedes der Attribute das für die Berechnung verwendet werden soll wird gemäß des DTW-Algorithmus eine Kostenmatrix aufgestellt (Listing 5.5). Für sie werden die minimalen Pfadkosten berechnet und zu den Gesamtkosten für diesen Attributvergleich addiert. Das Ergebnis wird am Ende durch die Anzahl der betrachteten Attribute geteilt, um auch vergleichbare Werte zu erhalten, wenn die Anzahl an Attributen variiert. Die Methode *build-CostMatrix* liefert die passende Kostenmatrix für ein gemeinsames Attribut zweier Frame-Listen gemäß des DTW-Algorithmus. Zunächst werden die beiden Attributreihen in Arrays kopiert. Anschließend wird die initiale Matrix erstellt. Die Zellen der Reihe und Spalte mit dem Index 0 werden mit dem Wert „unendlich“ belegt. Die Zelle (0, 0) und alle übrigen Zellen erhalten den Wert 0. Nun werden die Attributwerte paarweise verglichen. Hier wird standardmäßig die absolute Distanz verwendet. Bei Bedarf können an dieser Stelle weitere Distanzmetriken ergänzt werden. Zur berechneten Differenz wird jeweils das Minimum der angrenzenden, bereits berechneten Zellen addiert. Diese Summe wird in die entsprechende Matrixzelle eingetragen. Dadurch füllt sich die Matrix und kann nach Abschluss der Berechnungen zurückgegeben werden. Die Kosten des Warping Pfads der entsprechenden Matrix können mithilfe der Methode *calculatePathCost* berechnet werden. Das Verfahren startet in der letzten Zelle der Matrix und sucht den Pfad mit den geringsten Kosten, um die Zelle (0, 0) zu erreichen. Dabei werden die in Abschnitt 3.2 beschriebenen Vorgaben eingehalten. Die Kosten des Pfades werden aufsummiert und anschließend durch die Anzahl der betretenen Zellen geteilt. Diese Division ist nötig, um im Falle von unterschiedlich großen Matrizen vergleichbare Ergebnisse zu erhalten. Listing 5.6 veranschaulicht dieses Vorgehen.

```

1  do {
2      // Reset for next loop iteration.
3      cost = this.dtw.calculateCost(
4          this.clusterImpls.get(0).getMedianFrames(),
5          this.clusterImpls.get(1).getMedianFrames());
6      currentMinimumCost = cost;
7      mergeCandidate1 = 0;
8      mergeCandidate2 = 1;
9      for (ClusterImpl clusterImpl1 : this.clusterImpls) {
10         for (ClusterImpl clusterImpl2 : this.clusterImpls) {
11             if (
12                 clusterImpl1 != clusterImpl2
13                 && clusterImpl1.isConsider()
14                 && clusterImpl2.isConsider()) {
15                 if (this.calculatedCost.containsKey(
16                     new ClusterKey(clusterImpl1, clusterImpl2))) {
17                     cost = this.calculatedCost.get(
18                         new ClusterKey(clusterImpl1, clusterImpl2));
19                 }
20                 else {
21                     cost = this.dtw.calculateCost(
22                         clusterImpl1.getMedianFrames(),
23                         clusterImpl2.getMedianFrames());
24                     this.calculatedCost.put(
25                         new ClusterKey(clusterImpl1, clusterImpl2), cost);
26                 }
27                 if (cost < currentMinimumCost) {
28                     /* If a cost smaller than the current minimum cost
29                      has been found it will be the new minimum. */
30                     currentMinimumCost = cost;
31                     mergeCandidate1 = this.clusterImpls.indexOf(clusterImpl1);
32                     mergeCandidate2 = this.clusterImpls.indexOf(clusterImpl2);
33                 }
34             }
35         }
36     }
37     // Merging. Shown in next Listing.
38 } while (currentMinimumCost < threshold && this.clusterImpls.size() > 1);

```

Listing 5.2: Cluster-Methode: Berechnungsvorgang.

```

1  if (currentMinimumCost < threshold) {
2      /* MergeCandidate1 and mergeCandidate2 should be merged together.
3      Merge cluster2 into cluster1 and update the cluster list.
4      Consider of cluster2 is set to false. */
5      this.clusterImpls.get(mergeCandidate1).mergeWithCluster(
6          this.clusterImpls.get(mergeCandidate2));
7      this.clusterImpls.remove(this.clusterImpls.get(mergeCandidate2));
8      // Create a copy of the map to avoid an exception.
9      Map<ClusterKey, Double> calculatedCostCopy = new HashMap<>(calculatedCost);
10     /* remove all calculated costs from the map that contain
11     cluster1 because it changed and therefore all cost values
12     with this cluster have to be calculated again. */
13     for (Map.Entry<ClusterKey, Double> entry : calculatedCostCopy.entrySet()) {
14         /* Ignore mergeCandidate2 because it got removed from the list and
15         the consider value of cluster2 is set to false. */
16         if (entry.getKey().getCluster1().getId() == mergeCandidate1
17             || entry.getKey().getCluster2().getId() == mergeCandidate1) {
18             for (ClusterImpl clusterImpl : clusterImpls) {
19                 calculatedCost.remove(
20                     new ClusterKey(
21                         this.clusterImpls.get(mergeCandidate1), clusterImpl));
22             }
23         }
24     }
25 }

```

Listing 5.3: Cluster-Methode: Mergevorgang.

```

1  public double calculateCost(
2      List<FrameImpl> frames1,
3      List<FrameImpl> frames2) {
4      // Add the calculated cost of each attribute to it.
5      double cost = 0;
6      // calculate the cost for all attributes
7      for (String attribute : this.usedAttributes) {
8          // Build the cost matrix for this attribute.
9          double[][] dtwMatrix = buildCostMatrix(frames1, frames2, attribute);
10         // Calculate and add the cost of this attribute.
11         cost += calculatePathCost(dtwMatrix);
12     }
13     return cost / this.usedAttributes.size();
14 }

```

Listing 5.4: DTW: Berechnung der Kosten.

5.3 Abweichungen zur Konzeption

An die Performanz der Anwendung wurden keine besonderen Anforderungen gestellt (Unterabschnitt 4.1.1). Es zeigte sich aber schnell, dass bereits Datensätze mit einigen Hundert Records zu langen Bearbeitungszeiten führen. Daher wurden zwei Konzepte umgesetzt die sich diesem Problem annehmen. Zum einen werden die berechneten Kosten in einer Map abgespeichert, um wiederholte Berechnungen in darauffolgenden Schritten zu vermeiden. Als Key der jeweiligen Map-Einträge dient ein Objekt der Klasse *ClusterKey*. Sie implementiert das *Comparable*-Interface und sorgt dafür, dass zwei Cluster zusammen als Key einer Map verwendet werden können. Dies spart viele Berechnungsschritte, da beinahe alle Werte im Vergleich zum vorherigen Iterationsschritt gleich bleiben. Lediglich jene Kosten an denen die neu zusammengeführten Cluster beteiligt waren, sowie die Kosten mit dem neuen Cluster müssen neu berechnet werden. Zum anderen gibt es die Möglichkeit jeden dritten Frame der Records zu ignorieren. Dies geschieht, indem der Parameter *skipFrames* in der config-Datei auf *true* gesetzt wird. Damit ist in der Regel weiterhin ein sinnvolles Clustering möglich, wobei die Anzahl der Berechnungsschritte reduziert werden kann. Es ist zu erwähnen, dass es dabei zu einem Informationsverlust kommt. Diese Option sollte daher nur bei Bedarf genutzt werden.

Zudem wurde abweichend zur Konzeption ein primitiver *Visualizer* ergänzt, da sonst die


```

1 private double[][] buildCostMatrix(
2     List<FrameImpl> frames1,
3     List<FrameImpl> frames2,
4     String attribute) {
5     double[] s = new double[frames1.size()];
6     double[] t = new double[frames2.size()];
7     int counter = 0;
8     for (FrameImpl frame : frames1) {
9         s[counter] = Double.parseDouble(frame.getValue(attribute));
10        counter += 1;
11    }
12    counter = 0;
13    for (FrameImpl frame : frames2) {
14        t[counter] = Double.parseDouble(frame.getValue(attribute));
15        counter += 1;
16    }
17    int n = s.length;
18    int m = t.length;
19    // Filled with zeros by default.
20    double[][] dtwMatrix = new double[n + 1][m + 1];
21    for (int i = 0; i < dtwMatrix.length; i++) {
22        for (int j = 0; j < dtwMatrix[0].length; j++) {
23            // filled with infinity by definition of dtw
24            dtwMatrix[i][j] = Double.POSITIVE_INFINITY;
25        }
26    }
27    // Filled with zero by definition of dtw.
28    dtwMatrix[0][0] = 0;
29    for (int i = 1; i < dtwMatrix.length; i++) {
30        for (int j = 1; j < dtwMatrix[0].length; j++) {
31            double cost = Math.abs(s[i - 1] - t[j - 1]);
32            double minTmp = Math.min(dtwMatrix[i - 1][j], dtwMatrix[i][j - 1]);
33            double lastMin = Math.min(minTmp, dtwMatrix[i - 1][j - 1]);
34            dtwMatrix[i][j] = cost + lastMin;
35        }
36    }
37    return dtwMatrix;
38 }

```

Listing 5.5: DTW: Kostenmatrix.

```

1 public double calculatePathCost(double[][] dtwMatrix) {
2     int n = dtwMatrix.length - 1;
3     int m = dtwMatrix[n - 1].length - 1;
4     int pathCounter = 1;
5     double cost = dtwMatrix[n][m];
6     while (n != 0 && m != 0) {
7         // dynamic time warping algorithm
8         double minTmp = Math.min(dtwMatrix[n - 1][m], dtwMatrix[n][m - 1]);
9         double lastMin = Math.min(minTmp, dtwMatrix[n - 1][m - 1]);
10        cost += lastMin;
11        if (lastMin == dtwMatrix[n - 1][m - 1]) {
12            n = n - 1;
13            m = m - 1;
14        }
15        else if (lastMin == dtwMatrix[n - 1][m]) {
16            n = n - 1;
17        }
18        else if (lastMin == dtwMatrix[n][m - 1]) {
19            m = m - 1;
20        }
21        pathCounter += 1;
22    }
23    return cost / pathCounter;
24 }

```

Listing 5.6: DTW: Warping Path berechnen.

5 Implementierung

Analyse der Cluster manuell über Kinect Studio erfolgen muss. Er stellt die Laufwege der gefundenen Cluster aus der Vogelperspektive dar. Für jedes Cluster wird ein Verzeichnis erstellt. Darin werden die einzelnen Komponenten visualisiert.

6 Evaluation

Um die Praxistauglichkeit zu überprüfen, werden nun ausgewählte Daten mithilfe des entwickelten Tools geclustert. Die Ergebnisse werden bewertet. Zur Bewertung des Clusterings unterscheidet man *externe* und *interne* Indizes (Aghabozorgi et al., 2015; Warren Liao, 2005). Bei einem *externen Index* werden *Ground-Truth-Daten* extern bereitgestellt. Nach dem Clustering kann der Grad der Übereinstimmung zwischen gefundenen Cluster und den vorgegebenen Clustern überprüft werden. In diesem Kapitel werden die Daten mithilfe der Visualisierung manuell geclustert. In Abschnitt 6.2 werden die gefundenen Cluster mit den erwarteten verglichen. Bei *internen Indizes* muss die Qualität der Cluster hingegen ohne zusätzliche Informationen überprüft werden (Aghabozorgi et al., 2015; Warren Liao, 2005). Dazu sollen in Abschnitt 6.3 *deskriptive Statistiken* genutzt werden. Die Standardabweichung, der Mittelwert, das Maximum und das Minimum liefern ein Maß für die Ähnlichkeit von Cluster-Komponenten. Damit wird überprüft, ob zusammengefasste Records tatsächlich einen hohen Grad an Übereinstimmung aufweisen.

6.1 Einführende Bemerkungen

Statt den gesamten in Abschnitt 2.3 beschriebenen Datensatz zu verwenden sollen geeignete Teilmengen genutzt werden. Zudem wurden die Daten zur Evaluation gefiltert bereitgestellt. Zu kurze oder fehlerhafte Records wurden aussortiert. Außerdem erfolgte eine Sortierung nach Personenzahl. Das Filtern der Daten gehört nicht zu den Anforderungen an das entwickelte Tool und wird daher nicht in dieser Arbeit betrachtet. Dennoch sollte dem Nutzer bewusst sein, dass mit gefilterten Daten gegebenenfalls aussagekräftigere Ergebnisse erzielbar sind. Gerade die separate Betrachtung von Records unterschiedlicher Personenzahl kann helfen, wiederkehrende Bewegungsmuster durch Clustering zu erkennen. Die Anzahl gibt dabei immer an wie viele Personen sich maximal zu einem Zeitpunkt in der Aufnahme befinden. In der Evaluation werden nur Records mit ein bis drei Personen betrachtet.

Ebenfalls zu erwähnen ist die Bedeutung eines geeigneten Threshold-Wertes für ein er-

folgreiches Clustering. Dieser kann je nach vorliegenden Daten, verwendeten Attributen und Zielstellung variieren. Häufig ist daher ein „Herantasten“ nötig. In den später beschriebenen Szenarien war beispielsweise auffällig, dass der Threshold bei Records mit einer Person deutlich niedriger war, als bei Records mit mehreren Personen. Abhängig davon wie viele Cluster am Ende erwünscht sind und wie stark die Cluster-Bestandteile voneinander abweichen dürfen, muss ein anderer Wert gewählt werden.

Die Ground-Truth-Daten wurden manuell mithilfe der Visualisierung erstellt. Zunächst werden drei Minimalbeispiele betrachtet. Dafür wurden für die Fälle eine bis drei Personen jeweils beliebig 25 Records gewählt. Diese wurden mithilfe des Visualizers und Kinect Studio visualisiert und manuell in Cluster eingeteilt. Abbildung 6.1 zeigt jeweils die Visualisierung eines Repräsentanten der Cluster. Die Ergebnisse und eine sprachliche Beschreibung des Inhalts können im *resources*-Verzeichnis des Projektordners eingesehen werden. Das hierarchische Clustering wurde mit den x- und z-Werten als Vergleichsattribute gestartet. Der Threshold wurde dabei jeweils so gewählt, dass genau so viele Cluster entstehen wie auch manuell erkannt wurden. Die Auswertung zeigt, dass die vom Tool berechneten Cluster genau mit den Ground-Truth Daten übereinstimmen. Diese Minimalbeispiele sind aber nur bedingt aussagekräftig, da lediglich eine kleine Teilmenge der tatsächlich vorhandenen Daten genutzt wird. Manche Muster treten dadurch gegebenenfalls überhaupt nicht auf. In Abschnitt 6.2 soll daher die Analyse auf alle vorhandenen gefilterten Daten für ein bis drei Personen ausgeweitet werden. Aufgrund der Vielzahl der Daten ist das manuelle Clustering allerdings nicht so zuverlässig möglich wie in den oben beschriebenen Minimalbeispielen. Die Daten wurden aber nach bestem Wissen auf die wichtigsten Bewegungen hin untersucht. Spezielle Bewegungen die nur einmalig auftreten wurden ignoriert. Ziel ist es zu überprüfen, ob häufig wiederkehrende Muster vom Tool korrekt erkannt werden.

6.2 Ground-Truth Analyse

Im gefilterten Datensatz mit drei Personen befinden sich insgesamt 103 Records. Die manuelle Einteilung ergab, dass es sich bei den meisten darin vorkommenden Bewegungsabläufen um spezielle Bewegungen handelt, die nicht häufiger auftreten. Sie sollen im Folgenden nicht aufgeführt werden. Allerdings wurde ein eindeutiges Cluster identifiziert. Abbildung 6.2 zeigt einen Repräsentanten dieses Clusters. Es handelt sich dabei um drei Personen die nebeneinander durch den Sensorbereich laufen. Die selben Erkenntnisse lieferte auch das Minimalbeispiel aus Abschnitt 6.1. Grund hierfür kann sein, dass die Datenmenge mit circa 100

Records immer noch gering ist. Anschließend wurde überprüft, ob diese häufig auftretende Bewegung auch vom Tool korrekt erkannt wird. Die Ergebnisse der Berechnungen stimmen mit den manuell gefundenen Daten überein. Im Wesentlichen wird nur ein nicht-triviales Cluster gefunden und zwar das oben Beschriebene.

Die Teilmenge aller Records mit zwei Personen enthält 513 Records. Bei der manuellen Durchsicht lassen sich wieder spezielle, nicht wiederkehrende Bewegungen erkennen. Diese werden erneut ignoriert. Im Gegensatz zum Fall mit drei Personen sind hier aber mehrere häufig auftretende Bewegungen identifizierbar. Abbildung 6.3 zeigt jeweils einen Repräsentanten dieser manuell erkannten Muster. Zum einen handelt es sich um den Fall, dass zwei Personen durch den Aufnahmebereich laufen. Dies ist die analoge Bewegung zum gefundenen Cluster bei drei Personen. Der zweite Fall zeigt, wie sich zwei Personen dem Sensor nähern. In Szenario drei bewegt sich eine Person zur Kamera, während eine Andere lediglich durch das Bild läuft. Im letzten Fall laufen zwei Personen gemeinsam zum oberen Bildrand. Alle Szenarien werden durch das Tool gefunden. Bei dieser großen Menge an Records fällt auf, dass bei niedrigen Thresholds ähnliche Records teilweise noch in unterschiedlichen Clustern liegen und erst in späteren Schritten kombiniert werden, da andere Szenarien noch eine höhere Ähnlichkeit aufweisen.

Das Tool kann für Datensätze mit Ein- bis Zweitausend Records effizient eingesetzt werden. Auf einem heute typischen Mittelklasse-Heimrechner werden innerhalb weniger Minuten Ergebnisse geliefert. Ab einigen Tausend Records nimmt die Bearbeitungszeit zu, sodass unter Umständen mit mehreren Stunden Wartezeit zu rechnen ist. Die meisten Hierarchischen Clustering-Verfahren werden den Komplexitätsklassen $O(n^2)$ oder $O(n^3)$ zugeordnet. Das implementierte Tool fällt in die Klasse $O(n^2)$, wie die Zeitmessungen aus Tabelle 6.1 belegen. Die Verdoppelung der Recordanzahl führt nicht zu einer Verachtfachung der Bearbeitungszeit, wie dies bei $O(n^3)$ der Fall wäre. Die Zeit zum Einlesen der Daten und zum Schreiben der Ergebnisse wurde hier ignoriert. Diese Limitierung muss beachtet werden, falls in Zukunft noch größere Datenmengen geclustert werden müssen. Dann muss entweder ein leistungsfähigerer Rechner eingesetzt werden, oder das Tool weiter optimiert werden. Beispielsweise kann über Parallelisierung nachgedacht werden oder eine effizientere Version des Clustering-Verfahrens implementiert werden. Patel et al. (2015) stellen einige mögliche Varianten vor.

Insgesamt befinden sich 3523 Records mit einer Person im gefilterten Datensatz. Ab einer gewissen Menge treten allerdings kaum noch neue Bewegungsmuster auf. Deshalb soll

Recordanzahl	Bearbeitungszeit (Sekunden)
100	9
200	30
400	133
800	637

Tabelle 6.1: Bearbeitungszeiten des Clusteringvorgangs nach Recordanzahl.

die Analyse im Folgenden auf eine Teilmenge mit 1000 beliebigen Records eingeschränkt werden. Erneut wird überprüft, ob wiederkehrende Bewegungen korrekt erkannt werden. Abbildung 6.4 zeigt jeweils einen Repräsentanten der manuell erkannten Muster. Im ersten Fall bewegt sich eine Person durch den Aufnahmebereich, während sie sich im zweiten Szenario unmittelbar vor der Kamera befindet. Bild drei zeigt ein direktes Zugehen auf den Bildschirm. Im vierten Fall und sechsten Fall steht die Person an verschiedenen Positionen beinahe still. Szenario fünf zeigt, wie eine Person nach vorne läuft, sich umdreht und wieder zurück läuft. All diese Fälle können durch das Tool erkannt werden. Zu erwähnen ist allerdings, dass manche Cluster bei hohen Thresholds bereits in andere Muster integriert werden. So kann etwa das fünfte Szenario nur bei niedrigeren Thresholds erkannt werden, während es bei höheren Werten unter Umständen bereits mit Cluster eins zusammengeführt wurde. Dies verdeutlicht erneut, dass eine sinnvolle Suche nach Clustern möglich ist, diese aber dennoch manuell betrachtet werden müssen. Dabei sollte auch mit verschiedenen Thresholds experimentiert werden.

Die Auswertung des gesamten Datensatzes bestätigt also was die Minimalbeispiele bereits vermuten liesen. Das Tool kann erfolgreich genutzt werden, um sinnvolle Cluster auf den Kinect-Bewegungsdaten zu finden. Im Folgenden Abschnitt soll abschließend die Güte der gefundenen Cluster an einigen Beispielen überprüft werden.

6.3 Statistische Analyse

Abschließend soll mithilfe von *deskriptiven Statistiken* überprüft werden, ob ein Zusammenhang zwischen den Record-Bestandteilen eines Clusters besteht. Der Grad der Übereinstimmung liefert Informationen zur Ähnlichkeit. Konkret werden nun für die Komponenten einiger Cluster die Standardabweichung, der Mittelwert, das Maximum und das

Minimum für die x-Laufwege berechnet und tabellarisch dargestellt werden. In der letzten Zeile ist jeweils die Standardabweichung aller darüberstehenden Werte aufgeführt. Hier werden teilweise die Minimalbeispiele aus Abschnitt 6.2 mit veränderten Thresholds wieder aufgegriffen. Auch diese Daten befinden sich im *resources*-Verzeichnis des Projektordners. Zunächst wird das erste Cluster mit drei Personen betrachtet (Abbildung 6.1). Die Ergebnisse werden in Tabelle 6.2 dargestellt und sind auf zwei Nachkommastellen gerundet. Anschließend werden die Werte des ersten Clusters mit zwei Personen aus Abbildung 6.1 berechnet. Sie sind in Tabelle 6.3 zu sehen. Setzt man im selben Beispiel den Threshold noch höher, sodass die gefundenen Cluster augenscheinlich nicht mehr sinnvoll sind, erhält man die Werte in Tabelle 6.4. Die Mittelwerte und Standardabweichungen in den ersten beiden Beispielen bewegen sich jeweils in einem ähnlichen Rahmen. Auch die Standardabweichung dieser Werte ist mit 0.16 und 0.09 im ersten, sowie 0.16 und 0.08 im zweiten überprüften Cluster gering. Dadurch wird bestätigt, dass die Records einen inhaltlichen Zusammenhang aufweisen. Beim dritten Fall hingegen schwanken diese Werte stärker. Die ermittelte Gesamtstandardabweichungen sind mit 0.31 und 0.12 auch um circa 52 Prozent, bzw. 39 Prozent höher als bei den zuerst betrachteten Clustern. Einige Records scheinen also nicht in die Gruppe zu passen. So weicht beispielsweise die Zeile *2017-04-04 14.55.11.727* stark von den anderen ab. Ein Blick in die Visualisierung bestätigt, dass dieser Laufweg nicht zu den anderen passt. Dieser Fall wurde lediglich aufgrund des hohen Thresholds einsortiert. Dies betont einerseits erneut die bedeutende Rolle eines geeigneten Thresholds und andererseits, dass die Bestimmung der Güte mittels deskriptiver Statistiken möglich ist. Die Records der Cluster der beiden ersten Beispiele weisen eine hohe Ähnlichkeit auf. Mithilfe des entwickelten Tools ist also ein sinnvolles Clustering möglich. Beim letzten Cluster sind durch einen hohen Threshold hingegen zu viele Records zusammengeführt worden.




Abbildung 6.1: Repräsentanten der manuell erstellten Cluster.




Abbildung 6.2: Repräsentant des nicht trivialen Clusters mit drei Personen.




Abbildung 6.3: Repräsentanten der größten Cluster mit zwei Personen.



Abbildung 6.4: Repräsentanten der größten Cluster mit einer Person.

Record	Minimum	Maximum	Mittelwert	Standardabw.
2017-05-04 16.35.15.463	-2.12	0.63	-0.59	0,72
2017-04-13 12.34.38.535	-1.72	0.46	-0.65	0,58
2017-05-08 12.30.56.954	-2.09	0.12	-1.01	0.56
2017-04-13 12.36.06.669	-1.83	0.43	-0.70	0.57
2017-04-20 12.35.56.578	-2.06	0.50	-0.75	0.67
2017-04-10 11.53.16.991	-2.09	-0.61	-1.15	0.36
2017-05-08 12.45.55.652	-1.84	0.51	-0.64	0.65
2017-04-06 09.47.43.189	-1.96	0.44	-0.66	0.64
2017-04-05 13.00.04.745	-1.79	0.17	-0.79	0.50
2017-04-11 13.29.55.196	-2.06	0.72	-0.47	0.72
2017-04-07 13.19.05.395	-2.01	0.32	-0.81	0.56
2017-04-21 14.17.23.301	-2.03	0.30	-0.91	0.59
2017-04-26 11.59.37.413	-1.74	0.31	-0.76	0.55
2017-04-21 12.58.27.894	-1.84	0.20	-0.81	0.51
2017-04-19 12.54.19.390	-1.81	0.66	-0.54	0.69
2017-04-27 12.36.45.995	-1.85	-0.04	-0.92	0.50
2017-05-04 13.13.17.884	-2.07	-0.03	-0.85	0.52
2017-04-05 09.28.25.562	-1.78	0.36	-0.66	0.58
2017-05-04 13.24.36.117	-2.00	0.38	-0.66	0.65
2017-04-05 13.01.44.147	-2.20	0.41	-0.73	0.63
2017-04-07 11.05.51.351	-1.89	0.32	-0.63	0.65
Standardabweichung	0.14	0.29	0.16	0.09

Tabelle 6.2: Deskriptive Statistiken für das Cluster mit drei Pers.

Record	Minimum	Maximum	Mittelwert	Standardabw.
2017-04-06 12.26.06.199	-1.90	-0.34	-0.98	0,49
2017-04-05 09.13.53.631	-1.73	0.01	-0.88	0,41
2017-04-04 16.54.30.868	-1.67	0.45	-0.61	0.61
2017-04-05 12.32.59.075	-1.71	0.30	-0.62	0.54
2017-04-05 12.53.33.743	-1.80	0.28	-0.67	0.55
2017-04-05 10.03.28.598	-1.89	-0.02	-1.00	0.51
2017-04-05 08.16.53.128	-1.77	-0.03	-0.88	0.48
2017-04-05 14.44.27.088	-1.87	0.31	-0.72	0.60
2017-04-06 12.31.41.933	-1.77	0.28	-0.70	0.61
2017-04-05 15.01.29.988	-1.95	0.58	-0.50	0.68
2017-04-04 17.27.46.240	-1.93	-0.32	-1.10	0.38
2017-04-05 15.02.00.252	-2.13	0.26	-0.83	0.65
2017-04-05 17.08.48.758	-1.76	0.30	-0.73	0.64
2017-04-05 16.59.22.830	-1.92	0.38	-0.74	0.57
2017-04-05 11.40.51.237	-1.32	0.17	-0.49	0.46
2017-04-06 11.38.42.632	-1.67	0.12	-0.81	0.50
2017-04-05 10.56.51.141	-1.77	0.31	-0.68	0.58
2017-04-05 12.29.05.007	-1.85	0.16	-0.80	0.55
2017-04-05 13.33.56.412	-1.97	0.31	-0.79	0.63
2017-04-05 10.59.42.469	-1.77	-0.17	-0.92	0.49
Standardabweichung	0.16	0.24	0.16	0.08

Tabelle 6.3: Deskriptive Statistiken für das Cluster mit zwei Pers.

Record	Minimum	Maximum	Mittelwert	Standardabw.
2017-04-06 12.26.06.199	-1.90	-0.34	-0.98	0,49
2017-04-05 09.13.53.631	-1.73	0.01	-0.88	0,41
2017-04-04 16.54.30.868	-1.67	0.45	-0.61	0.61
2017-04-05 12.32.59.075	-1.71	0.30	-0.62	0.54
2017-04-04 18.04.06.507	-1.23	1.07	-0.14	0.54
2017-04-05 12.53.33.743	-1.80	0.28	-0.67	0.55
2017-04-05 10.03.28.598	-1.89	-0.02	-1.00	0.51
2017-04-05 08.16.53.128	-1.77	-0.03	-0.88	0.48
2017-04-05 12.40.57.142	-1.52	-0.23	-1.00	0.22
2017-04-05 14.44.27.088	-1.87	0.31	-0.72	0.60
2017-04-06 12.31.41.933	-1.77	0.28	-0.70	0.61
2017-04-05 15.01.29.988	-1.95	0.58	-0.50	0.68
2017-04-04 17.27.46.240	-1.93	-0.32	-1.10	0.38
2017-04-04 14.55.11.727	-1.57	1.02	0.36	0.84
2017-04-05 15.02.00.252	-2.13	0.26	-0.83	0.65
2017-04-05 17.08.48.758	-1.76	0.30	-0.73	0.64
2017-04-05 16.59.22.830	-1.92	0.38	-0.74	0.57
2017-04-05 11.40.51.237	-1.32	0.17	-0.49	0.46
2017-04-05 11.41.21.472	-1.08	-0.14	-0.53	0.36
2017-04-06 11.38.42.632	-1.67	0.12	-0.81	0.50
2017-04-05 10.56.51.141	-1.77	0.31	-0.68	0.58
2017-04-05 12.29.05.007	-1.85	0.16	-0.80	0.55
2017-04-05 13.33.56.412	-1.97	0.31	-0.79	0.63
2017-04-05 10.59.42.469	-1.77	-0.17	-0.92	0.49
Standardabweichung	0.24	0.35	0.31	0.12

Tabelle 6.4: Deskriptive Statistiken für das Cluster mit zwei Pers. (hoher Threshold).

7 Fazit

Abbildungsverzeichnis

2.1	Audience Funnel Framework. Abbildung aus Mai und Hußmann (2018). . . .	4
2.2	Skelettpunkte der Kinect v2. Abbildung von Microsoft (2014).	5
2.3	Frame aus dem Datensatz.	7
2.4	Zuordnung der Messpunkte zweier Datenreihen.	8
3.1	Graphische Veranschaulichung der gebildeten Cluster.	14
4.1	Paketdiagramm des Tools.	20
5.1	Klassendiagramm des Tools.	23
6.1	Repräsentanten der manuell erstellten Cluster.	38
6.2	Repräsentant des nicht trivialen Clusters mit drei Personen.	39
6.3	Repräsentanten der größten Cluster mit zwei Personen.	39
6.4	Repräsentanten der größten Cluster mit einer Person.	39

Abkürzungsverzeichnis

HCI	Mensch-Computer-Interaktion
RGB	Rot-Grün-Blau
ToF	Time-of-Flight
DTW	Dynamic Time Warping
TSD	Time-Series Data

Listingsverzeichnis

5.1	Cluster-Methode: Initialisierung.	25
5.2	Cluster-Methode: Berechnungsvorgang.	27
5.3	Cluster-Methode: Mergevorgang.	28
5.4	DTW: Berechnung der Kosten.	29
5.5	DTW: Kostenmatrix.	30
5.6	DTW: Warping Path berechnen.	31

Tabellenverzeichnis

2.1	Attribute des Datensatzes.	6
3.1	Kostenmatrix mit hervorgehobenem Warping Pfad.	13
3.2	Erster Durchlauf der Kostenberechnung.	13
3.3	Zweiter Durchlauf der Kostenberechnung.	14
3.4	Dritter Durchlauf der Kostenberechnung.	14
4.1	Attribute der Configuration-Datei.	19
6.1	Bearbeitungszeiten des Clusteringvorgangs nach Recordanzahl.	36
6.2	Deskriptive Statistiken für das Cluster mit drei Pers.	40
6.3	Deskriptive Statistiken für das Cluster mit zwei Pers.	41
6.4	Deskriptive Statistiken für das Cluster mit zwei Pers. (hoher Threshold). . . .	42

Literaturverzeichnis

- Aghabozorgi, S., Seyed Shirkhorshidi, A., & Ying Wah, T. (2015). Time-series clustering – A decade review. *Information Systems*, 16–38. <https://doi.org/10.1016/j.is.2015.04.007>
- Ali, M., Alqahtani, A., Jones, M. W., & Xie, X. (2019). Clustering and Classification for Time Series Data in Visual Analytics: A Survey. *IEEE Access*, 181314–181338. <https://doi.org/10.1109/ACCESS.2019.2958551>
- Hautamaki, V., Nykanen, P., & Franti, P. (2008). Time-series clustering by approximate prototypes. *2008 19th International Conference on Pattern Recognition*, 1–4. <https://doi.org/10.1109/ICPR.2008.4761105>
- Li, L., et al. (2014). Time-of-flight camera—an introduction [SLOA190B]. *Technical white paper*. Verfügbar 10. März 2022 unter <https://www.ti.com/lit/wp/sloa190b/sloa190b.pdf>
- Mai, C., & Hußmann, H. (2018). The Audience Funnel for Head-Mounted Displays in Public Environments. *2018 IEEE 4th Workshop on Everyday Virtual Reality (WEVR)*, 5.
- Mankoff, J., Dey, A. K., Hsieh, G., Kientz, J., Lederer, S., & Ames, M. (2003). Heuristic Evaluation of Ambient Displays. *NEW HORIZONS*, 169–176. <https://doi.org/10.1145/642611.642642>
- Marin, G., Agresti, G., Minto, L., & Zanuttigh, P. (2019). A multi-camera dataset for depth estimation in an indoor scenario. *Data in Brief*, 104619. <https://doi.org/10.1016/j.dib.2019.104619>
- Microsoft. (2014). Human Interface Guidelines v2.0 [Windows-Developer-Center Microsoft Corporation]. Verfügbar 1. März 2022 unter <https://download.microsoft.com/download/6/7/6/676611B4-1982-47A4-A42E-4CF84E1095A8/KinectHIG.2.0.pdf>
- Mohammadzade, H., Hosseini, S., Rezaei-Dastjerdehei, M. R., & Tabejamaat, M. (2021). Dynamic Time Warping-Based Features With Class-Specific Joint Importance Maps for Action Recognition Using Kinect Depth Sensor. *IEEE Sensors Journal*, 9300–9313. <https://doi.org/10.1109/JSEN.2021.3051497>
- Patel, S., Sihmar, S., & Jatain, A. (2015). A study of hierarchical clustering algorithms. *2015 2nd International Conference on Computing for Sustainable Global Development (INDIACom)*, 537–541.
- Plischke, T. (2022). *Noch nicht abgeschlossen* (Masterarbeit). Universität der Bundeswehr München.
- Temiz, J. (2022). *Konzeption und Implementierung eines Datenanalyse-Werkzeugs für Body-Tracking-Kameras* (Bachelorarbeit). Universität der Bundeswehr München.
- Tölgyessy, M., Dekan, M., Chovanec, L., & Hubinský, P. (2021). Evaluation of the Azure Kinect and Its Comparison to Kinect V1 and Kinect V2. *Sensors*, 413. <https://doi.org/10.3390/s21020413>
- UniBw. (2021). Honeypot-Effekt an interaktiven Ambient Displays (HoPE) — Inf2. Verfügbar 28. Februar 2022 unter <https://www.unibw.de/inf2/forschung/projekte/hope>
- Wahyuni, S., Rismayani, Intan, I., Ahyuna, A., & Suryani, S. (2021). Motion Recognition System with Dynamic Time Warping Method using Kinect Camera Sensor. *2021 3rd International*

- Conference on Cybernetics and Intelligent System (ICORIS)*, 1–4. <https://doi.org/10.1109/ICORIS52787.2021.9649520>
- Warren Liao, T. (2005). Clustering of time series data—a survey. *Pattern Recognition*, 1857–1874. <https://doi.org/10.1016/j.patcog.2005.01.025>
- Wouters, N., Downs, J., Harrop, M., Cox, T., Oliveira, E., Webber, S., Vetere, F., & Vande Moere, A. (2016). Uncovering the Honeypot Effect: How Audiences Engage with Public Interactive Systems. *Proceedings of the 2016 ACM Conference on Designing Interactive Systems*, 5–16. <https://doi.org/10.1145/2901790.2901796>
- Yu, X., & Xiong, S. (2019). A Dynamic Time Warping Based Algorithm to Evaluate Kinect-Enabled Home-Based Physical Rehabilitation Exercises for Older People. *Sensors*, 2882. <https://doi.org/10.3390/s19132882>

Hiermit versichere ich, die vorliegende Arbeit selbständig und ohne fremde Hilfe verfasst, die Zitate ordnungsgemäß gekennzeichnet und keine anderen, als die im Literatur/Schriftenverzeichnis angegebenen Quellen und Hilfsmittel benutzt zu haben.

Ferner habe ich vom Merkblatt über die Verwendung von studentischen Abschlussarbeiten Kenntnis genommen und räume das einfache Nutzungsrecht an meiner Bachelorarbeit der Universität der Bundeswehr München ein.

München, den 31. Mai 2022

.....

(Unterschrift)